

哈尔滨工业大学（深圳）毕业论文（设计）任务书

姓 名	詹咏庭	学 号	2023312412
专 业	自动化		
任务起至日期	2026-09-23至2027-05-18		
论文（设计）题目	多轮大语言模型智能体中步骤-词元级优势的嵌套估计		
立题的目的和意义： 多轮大语言模型智能体（multi-turn LLM agent）的强化学习后训练中， 信用分配粒度是决定训练效率与最终性能的关键因素。当前主流方法各自在单一粒度上做优势估计，一是序列级如GRPO，以完整轨迹为单元计算组内相对优势，信号最粗，无法定位轨迹内部哪一步、哪个词元贡献了奖励；二是步骤级如GiGPO，以agent的动作步为单元，通过相同环境观测的轨迹分组计算步级相对优势，但步内部仍无区分；三是词元级如TAPO的熵过滤，利用策略熵识别关键推理token，能定位“哪个词元是决策关键”，但缺乏对多轮交互结构的建模。本课题的核心目的在于讨论步骤级与词元级两个粒度的信用分配是否能正交组合产生叠加增益，目前文献中尚无工作系统性地回答这一问题，GiGPO和TAPO/TEMPO分别独立提出并验证了各自的有效性，但从未在统一框架下做对照消融，更未探索二者的乘法调制能否优于任一单独方法。因此本课题提出NEST（Nested Estimation of Step and Token advantages），旨在通过实证的方式探究两个粒度之间是否正交/加成/冗余，并实现一种轻量化的嵌套优势估计方式。			
技术指标与主要内容： 主要内容与技术指标： 主要研究内容： （1）步骤级信用分配（GiGPO anchor grouping）与词元级信用分配（TAPO熵过滤/TEMPO前缀树）在多轮agent训练中是否存在正交互作用，并通过置换实验验证两个粒度分别的作用。 （2）不同嵌套方式，如乘法调制和加法调制，是否存在效果差异。 （3）使用VeRL框架实现一个轻量化的后训练强化学习优势嵌套估计范式。 主要技术指标： （1）在ALFWorld、WebShop等benchmark上，完整NEST相比最强单一粒度方法成功率有3%的提升。 （2）两个粒度的消融实验，为说明该粒度的优势估计有意义，去掉其中一层的信息后，其成功率应降低5%以上。 （3）两个粒度的置换实验，打乱其中一个粒度的优势估计，其成功率应降低8%以上。			
进度安排： 2026年09月-2026年10月:阅读相关文献，了解现有的信用分配算法，完成开题报告。 2026年10月-2027年02月:复现现有的信用分配算法并完成嵌套思想的最小可行性验证，跑通pipeline。 2027年02月-2027年05月:最终实现嵌套优势估计，对多种算法以及嵌套方式进行对比分析，并撰写毕业论文			
同组设计者及分工： 无。			

指导教师签字：

梅杰

2026年（Y）10月（M）08日
（D）

专业毕业论文（设计）领导工作小组意见：

同意。

组长签字：

龚有敏

2026年（Y）10月（M）08日
（D）

哈尔滨工业大学（深圳）毕业论文（设计）任务书

姓 名		学 号	
专 业			
任务起至日期			
论文（设计）题目			
立题的目的和意义：			
技术指标与主要内容：			
进度安排：			
同组设计者及分工：			
指导教师签字：			
专业毕业论文（设计）工作小组意见：			
组长签字：			