

Math(快问快答版)

什么是凸优化

凸优化问题是目标函数和不等式约束都是凸函数，等式约束是仿射变换的优化问题，凸函数是指定义域是凸集并且满足 $f(\lambda \mathbf{x} + (1-\lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1-\lambda)f(\mathbf{y})$ (碗状，凸凹性保持不变，Hessian矩阵 $\nabla^2 f(\mathbf{x})$ 半正定)

凸优化问题有很多好的性质，最重要的是局部最优等于全局最优，不用担心local minima，便于使用梯度下降法

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^T (\mathbf{x} - \mathbf{x}_0) + (1/2)(\mathbf{x} - \mathbf{x}_0)^T H(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0)$$

这里最后一项,正是一个以 Hessian矩阵 $H(\mathbf{x}_0)$ 作为"系数矩阵"的二次型。

双线性变换

是把s域(连续时间)转换到z域(离散时间)的一种映射方法,公式是s和z之间的分式线性关系;它能彻底消除频谱混叠

李亚普诺夫稳定性

李亚普诺夫稳定性描述的就是：系统在平衡点（一阶导为0）附近受到微小扰动后，对于任意的 $\epsilon > 0$ （允许的最大偏离范围），都存在 δ （初始扰动的允许范围） > 0 ，使得只要 x_0 距离平衡点的距离小于 δ ，都有 x_t 距离平衡点的距离小于 ϵ ，也就是说 x_t 的最大偏移可由初始扰动大小限制

渐进稳定：在李亚普诺夫稳定的基础上，还满足 x_t 最终会回到平衡点

不稳定就是一旦有微小扰动 x_t 就会跑出某个范围之外

KL散度、熵

$$D_{KL}(P\|Q) = \mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right]$$

$$H(P) = \mathbb{E}_{x \sim P} [-\log P(x)]$$

高数

二次积分和二重积分的区别和联系

二重积分属于黎曼积分的一种，以平面上的几何形体为微元进行积分；二次积分则是对多元函数，对几个变量先后进行累次积分，把多元问题拆成多次一元积分

富比尼定理：在 f 连续或可积的情况下，二重积分在数值上等于累次积分，重积分是通过累次积分计算的

多元极限和累次极限

$\forall \varepsilon > 0, \exists \delta > 0$, 使得当 $0 < \sqrt{(x-x_0)^2 + (y-y_0)^2} < \delta$ 时, 都有 $|f(x,y) - A| < \varepsilon$, (x,y) 以任意方式(任意路径)趋近于 (x_0, y_0) 时, 函数值都要趋于同一个 A , 这个极限也叫二重极限或重极限, 强调的是"两个变量同时、一起趋近", 不分先后顺序。

累次极限是依次、逐个变量求极限: $\lim\{x \rightarrow x_0\} [\lim\{y \rightarrow y_0\} f(x,y)]$ 或 $\lim\{y \rightarrow y_0\} [\lim\{x \rightarrow x_0\} f(x,y)]$ 先固定 x , 让 $y \rightarrow y_0$, 算出一个只跟 x 有关的函数, 再让 $x \rightarrow x_0$ 求这个函数的极限(或者反过来, 先固定 y 求 x 的极限), 这是两次一元极限依次嵌套完成的

- 重极限存在, 不能推出两个累次极限都存在
- 两个累次极限都存在且相等, 也不能推出重极限存在
- 如果重极限存在, 且累次极限也存在, 那么它们必然相等

什么是连续? 什么是可导?

连续指 $f(x)$ 在 x_0 处的极限值等于 $f(x_0)$, 在 x_0 处可导指 $[(f(x) - f(x_0))/(x - x_0)]$ 在 x 趋近于 x_0 时收敛, (极限存在并且左导数等于右导数) 可导一定连续, 连续不一定可导

多元函数可积的条件

可积和黎曼可积不完全是一回事, 黎曼可积有严格的数学定义, 而可积有的时候是比较宽泛的说法, 包括黎曼可积、勒贝格可积、广义积分收敛等等

黎曼可积的定义: 黎曼和的极限严格存在, 并且这个极限值不依赖几何形体的分割方式和取点方式 (只要子形体足够小即可)

可积的必要条件: 有界性

常用的充分条件: 1 有界闭区域的连续函数必然可积

2 有界且只有有限个第一类间断点

勒贝格判别法则用于判断黎曼可积: "有界函数黎曼可积 $\Leftrightarrow$ 间断点集合的测度为零"

什么是黎曼积分

黎曼积分是对几何形体上定义的点函数进行的积分, 以分割的几何形体为微元。包括定积分、二重积分、三重积分、第一型曲线和曲面积分。密度积分得到质量就属于黎曼积分。

Lebesgue 积分 (勒贝格积分)

Lebesgue 积分的核心想法是换一种"切法"。Riemann 积分是沿定义域(横轴)切成小区间, 在每个小区间上用函数值近似; Lebesgue 积分反过来, 沿值域(纵轴)切, 把每个高度区间对应的定义域子集测出"大小"来加权求和。这个转变解决了 Riemann 积分处理不好的两类问题: 振荡剧烈的函数、以及涉及极限交换的问题。

什么是梯度、散度、旋度

数量场梯度是个向量, $(\partial P / \partial x, \partial Q / \partial y, \partial R / \partial z)$, 指向函数值变化率最大的方向

散度: 一个标量, 描述流体在该点的源汇强度 (正值代表源, 向外流), $\text{div } v = \partial P / \partial x + \partial Q / \partial y + \partial R / \partial z$

旋度: 一个向量, 方向由右手定则确定(沿转动轴方向), 大小反映局部旋转的强弱, $\text{rot } v = (\partial R / \partial y - \partial Q / \partial z, \partial P / \partial z - \partial R / \partial x, \partial Q / \partial x - \partial P / \partial y)$

什么是通量和环量

通量：向量场穿过某个曲面的"净流量"（第二型曲面积分）

环量：向量场沿着某条闭曲线的"净环绕效应"（第二型曲线积分）

散度是通量的局部密度，高斯定理描述了闭表面上的通量等于其包围体内散度的三重积分

旋度是环量的局部密度，斯托克斯公式描述了闭曲线上的环量等于其包围的曲面的旋度的第二型曲面积分，格林公式是斯托克斯在平面上的特殊情况

简述梯度下降法

求解无约束优化问题最基础、最常用的迭代算法,核心思想是:沿着负梯度方向走,函数值下降得最快

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \cdot \nabla f(\mathbf{x}_k)$$

三个中值定理

罗尔中值定理

拉格朗日中值定理

柯西中值定理

洛必达法则

用于求解未定式极限，当极限出现 $0/0$ 或 ∞/∞ 这种未定式的形式时,可以转而求两个函数导数之比的极限

前提：满足未定式； f'/g' 极限存在，否则不能说原极限不存在，只能说洛必达法则失效

连续与一致连续/收敛与一致收敛

一致连续: $\forall \varepsilon > 0, \exists \delta > 0$ (只依赖于 ε , 与 x 无关), 使得对任意 $x_1, x_2 \in D$, 只要 $|x_1 - x_2| < \delta$, 就有 $|f(x_1) - f(x_2)| < \varepsilon$ 。

一致收敛: $\forall \varepsilon > 0, \exists N$ (只依赖于 ε , 与 x 无关), 使得当 $n > N$ 时, 对任意 $x \in D$, 都有 $|S_n(x) - S(x)| < \varepsilon$ 。

连续和一致连续的关系,跟"逐点收敛 vs 一致收敛"是完全平行的结构——区别都在于"控制误差所需的東西能不能跟位置无关"。

解析的定义

$f(x)$ 在 x_0 及 x_0 的领域内满足复可导（需要导数极限从各个方向看都存在），判断条件为存在连续偏导数且满足柯西-黎曼方程（充分）

$f(x)$ 在区域内满足复可导，则其高阶导数仍然满足复可导

复可导比二元实可微更强, 复可导 = 二元实可微 + 柯西-黎曼方程

二元实可微：设 $u(x, y)$ 在点 (x_0, y_0) 处可微, 是指存在线性近似:

$$u(x_0 + \Delta x, y_0 + \Delta y) = u(x_0, y_0) + u_x \Delta x + u_y \Delta y + o(\sqrt{(\Delta x)^2 + (\Delta y)^2})$$

孤立奇点

设函数 $f(z)$ 在点 z_0 的**去心邻域**($0 < |z - z_0| < r$, 即 z_0 本身除外的一圈小邻域)内**解析**,但在 z_0 **本身**要么没有定义,要么虽然有定义但不解析(不满足复可导),则称 z_0 是 f 的**孤立奇点**。

奇点可分为可去奇点、极点和本性奇点

洛朗级数是什么

是复变函数中的一种幂级数,它包含正数和负数次数的项,适用于在奇点附近展开解析函数。洛朗级数是针对函数 f 在以 b 为圆心的环形区域解析是对环形区域内的点在 b 处展开的级数(正幂次项代表某个圆内解析,负幂次项代表某个圆外解析)。其系数 a_n 是 $f/(x-b)^{(n+1)}$ 在环内的闭曲线的积分除 $2\pi \cdot i$ 。

1. 洛朗级数 (Laurent Series)

复变函数 $f(z)$ 在**环形区域** $r < |z - z_0| < R$ 内的展开:

$$f(z) = \sum_{n=-\infty}^{+\infty} c_n (z - z_0)^n = \underbrace{\sum_{n=0}^{\infty} c_n (z - z_0)^n}_{\text{解析部分}} + \underbrace{\sum_{n=1}^{\infty} \frac{c_{-n}}{(z - z_0)^n}}_{\text{主要部分}}$$

- **解析部分**: 正幂项, 在 z_0 处解析
- **主要部分**: 负幂项, 反映 z_0 处的奇异行为

可去奇点是指洛朗级数没有负幂次项,在只要调整 $f(b)$ 的值,在 b 点也可以解析

极点是洛朗展开有有限个负幂项,最低次数为 $-m$ 则为 m 阶极点,在趋于 b 的极限为 ∞

本性奇点是有无穷个负幂项,不存在极限,可能趋近不同的值

- **洛朗级数**本身是**泰勒级数**(前面讨论过)的推广——泰勒级数只有正幂次项(适用于解析点附近),洛朗级数允许负幂次项(专门用来刻画奇点附近的行为)
- **留数(residue)**:洛朗级数里 c_{-1} 这一项的系数,叫做"留数",是复变函数里计算围道积分的核心工具(留数定理),
- 围道函数的积分值等于其内部留数和乘 $2\pi \cdot i$

狄利克雷条件

周期上绝对可积;有限个间断点;有限个极值点

积分中值定理

若 $f(x)$ 在 $[a, b]$ 上连续,则存在 $\xi \in [a, b]$,使得: $\int_a^b f(x) dx = f(\xi) \cdot (b-a)$

什么是泰勒公式? 什么是泰勒中值定理?

若 $f(x)$ 在 x_0 内有 n 阶导数,那么存在一个 x_0 的邻域内, $f(x)$ 都能展开成泰勒展开式

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} \cdot (x - x_0)^k + R_n$$

泰勒中值定理是指 R_n 取拉格朗日余项时, $R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot (x - x_0)^{n+1}$ (ξ 在 x_0 和 x 之间)

数列/函数极限的定义 (epsilon-N/epsilon-x/epsilon-delta语言)

任意 $\epsilon > 0$, 存在正整数 N , 使得 $n > N$ 时恒有 $|x_n - a| < \epsilon$, 称数列 x_n 极限为 a

任意 $\epsilon > 0$, 存在 x , 使得 $|x| > x$ 时 $|f(x) - A| < \epsilon$, 成 $f(x)$ 在 $x \rightarrow \infty$ 的极限是 A

任意 $\epsilon > 0$, 存在 δ , 使得 $0 < |x - x_0| < \delta$, 恒有 $|f(x) - A| < \epsilon$, 记 $f(x)$ 在 x_0 处极限是 A

lagrange 乘数法-求带条件的极值

- $z = f(x, y)$ 当 $\varphi(x, y) = 0$ 时的极值, 构造 lagrange 函数 $L(x, y, \lambda) = f(x, y) + \lambda \varphi(x, y)$ 。
- 求 L 的驻点, 即 $x \ y \ \lambda$ 偏导数 $= 0$, 即得。

闭区间连续函数满足介值定理, 零点存在定理, 最值定理

代数基本定理:

- n 次复系数多项式方程, 在复数域内有且只有 n 个根 (重根按重数计算)。

牛顿迭代法

(Newton's method)是求方程近似根的一种迭代算法,核心思路是用切线代替曲线,一步步逼近零点。

要解 $f(x) = 0$, 任取一个初始猜测 x_0 , 在点 $(x_0, f(x_0))$ 处作 f 的切线, 这条切线跟 x 轴的交点往往比 x_0 更接近真正的根, 把这个交点记作 x_1 , 再重复这个过程。

迭代公式 $x_{n+1} = x_n - f(x_n)/f'(x_n)$, 只要 $f'(x_n) \neq 0$, 这个过程就能一直迭代下去。

线代

什么是全等变换

全等变换某种程度上可以理解为正交变换+平移 (属于仿射变换), 变换前后线段的长度、图形的形状不发生改变

线性空间

线性空间和向量空间的定义基本一致 (线性空间加入了矩阵)

n 维线性空间对加法和数乘运算封闭, 且满足八条规律 (包括交换律、结合律、存在零元和负元, 对数乘满足分配律, 存在单位元, 满足可加性和齐次性等等)

等价、相似、合同

AB 等价是指 A 可以经过有限次初等变换得到 B , 等价变换不改变秩

AB 相似指存在可逆矩阵 P , 使得 $P^{-1}AP = B$, 相似变换不改变特征值 (有相同的特征多项式), 也不改变迹和行列式

AB 合同指存在可逆矩阵 C , 使得 $C^T AC = B$, 合同变换不改变正负惯性系数

相似和合同都具有自反、对称、传递性

行列式、秩、迹

行列式： n 阶行列式是所有取自不同行、不同列的 n 个元素乘积的代数和；每一项必须恰好包含每一行一个元素、每一列一个元素，符号由列标排列的奇偶性决定。

几何意义：行列式 $\det(A)$ 的**绝对值**等于矩阵列向量（或行向量）张成的 n 维**平行多面体的体积**，符号则表示**定向**（手性）

秩：矩阵中线性无关的行/列向量的最大个数（行秩等于列秩）

矩阵的秩等于它的最高阶非零子式的阶数

迹：矩阵对角线元素之和。

线性变换

线性变换是指向量空间之间保持可加性和齐次性的映射。

正交变换

对线性空间中的元素乘正交矩阵对应的变换是正交变换，它不改变向量的形状和大小，只进行旋转($\det=1$)、反射($\det=-1$)等操作。

正交矩阵是转置等于逆的矩阵，其特征值的模长只会为1。（如果特征值是实数则只会为正负一）

恒等变换

对线性空间中的元素乘单位矩阵对应的变换是恒等变换，它将线性空间中的向量映射为自己本身

线性方程组的初等行变换

用非零常数 k 乘矩阵的某一行

互换矩阵某两行（列）的位置

把某行的 k 倍加至另一行

什么是Jordan标准型？

由主对角线为特征值、次对角线为1的约旦块按对角排列的矩阵

什么是正定矩阵

正定矩阵是一个实对称矩阵，对于任何 $x \neq 0$ ，满足二次型 $x^T A x$ 恒大于0

很多优化问题都涉及二次函数： $f(x) = 1/2 x^T A x + b^T x + c$

如果 A 是正定矩阵，那么这个函数是严格凸函数。这意味着它有唯一极小值，梯度等于零的点就是全局最小点。

如果 A 是实对称正定矩阵，则任意非零向量 x 与 Ax 的夹角小于 90° 。

什么是保角映射

保角变换，通常也叫**共形变换**或**共形映射**，是指一类能够保持角度不变的变换。

保角变换在局部保持曲线之间的夹角不变（但不保长度）。

举例：解析函数在导数不为0的地方是保角变换；分式线性变换（就是双线性变换那个）

线性变换不全都保角，如正交变换或均匀缩放是可以的

双线性

双线性(bilinear)指的是一个关于两个自变量分别都是线性的函数/映射——固定其中一个变量,对另一个变量是线性的;反过来固定另一个也一样。二次型就是双线性型的一个特殊情形。最常见的形式: 矩阵形式 $B(\mathbf{x}, \mathbf{y}) = \mathbf{x}^t \mathbf{A} \mathbf{y}$

几何重数与代数重数

代数重数是特征方程中特征值的重数

几何重数是Jordan标准型中该特征值对应的约旦块的个数,也是 $(\lambda I - A)\mathbf{X} = 0$ 的解空间的维度。

几何重数 $= \dim(\ker(\lambda I - A))$

几何重数肯定小于代数重数,当每个特征值的几何重数和代数重数都相等时,矩阵可以相似对角化。

什么是向量的范数和矩阵的范数

向量范数就是向量的长度(L1范数、L2欧几里得范数、无穷范数)满足非负、齐次、三角不等式等性质

矩阵范数是

行空间和列空间的关系?

行空间: 矩阵的行向量组成的空间。

列空间: 矩阵的列向量组成的空间。

一切矩阵的行秩数等于列秩数。

线性方程组有解的一致性条件/相容性条件:

$A\mathbf{x} = \mathbf{b}$ 有解。 $[A \mid \mathbf{b}]$ 与A的秩相等

若此时A满秩,则只有唯一解;若A不满秩,则有无穷多解

什么是标准正交基?

两两正交且长度为单位1的向量。

施密特正交化

是一种求标准正交基的方法,它通过对原基的每个向量减去已求得的基向量在该向量上的投影,从而得到相互正交的向量。再通过归一化得到标准正交基

什么是线性相关?

在n维向量组中,存在一个向量可以用有限个其他向量的线性组合所表示,则称为线性相关,没有一个向量可以表示则是线性无关。

什么是能控性、能观性?

能控性: 控制作用对被控系统状态进行控制的可能性。▪ 能观性: 由系统输出的测量值确定系统状态的可能性。

伴随矩阵

代数余子式 A_{ij} 排列好再转置

$$AA^* = A^*A = \det(A) \cdot I$$

矩阵的几何意义、特征值的几何意义

矩阵就是线性变换

给定 $\mathbb{R}^n \rightarrow \mathbb{R}^m$ 的线性映射 T (满足 $T(x+y)=T(x)+T(y)$, $T(cx)=cT(x)$), 一旦选定 $\mathbb{R}^n$ 和 $\mathbb{R}^m$ 的基, T 就完全由它把每个基向量送到哪里决定。把 $T(e_1), \dots, T(e_n)$ 依次作为列向量排起来, 就得到矩阵 A , 而 $T(x)=Ax$ 。矩阵 A 的第 i 列就是 $T(e_i)$, 即第 i 个基向量变换后的落点。

特征值与特征向量: 变换的“骨架方向”:

如果 $Av=\lambda v$, 说明沿方向 v , 变换只是简单地把长度缩放 λ 倍, 方向不变(或反向, 若 $\lambda < 0$)。这些方向是这个线性变换最“本征”的方向——在一般坐标下变换看起来很复杂(旋转+拉伸+切变混在一起), 但沿特征向量方向看, 行为退化成最简单的纯缩放。这也是为什么对称矩阵能被特征向量对角化后, 变换在这组新基下就是逐坐标独立缩放, 直观上就是沿几个正交方向分别拉伸。

行列式的几何意义

行列式 (det): “体积缩放倍率”。

它告诉你变换后, 这个立方体的体积变成了原来的多少倍。

方向感: 如果行列式为负, 说明空间被**翻转**了 (比如左手系变右手系)。

坍缩判断: 如果行列式为 0, 说明变换把空间压扁了 (体积归零), 矩阵不可逆。

ps: 同时行列式也代表其列向量张成的几何体的体积

迹 (tr): “平均拉伸量的总和”。

它告诉你变换在各个方向上**拉伸/压缩的净效果**的加总。

注意: 迹**不关心最终体积**, 它只关心沿坐标轴方向的“拉扯力度”之和。

矩阵范数

奇异值SVD分解

PCA主成分分析

PCA 就是对协方差矩阵 (这里的协方差指的是原高维数据的各维度的变量之间的协方差) 做特征分解(或对数据矩阵做 SVD), 取方差最大的前 k 个正交方向拼成投影矩阵 W , 把数据线性映射到这个低维正交坐标系里。

选取方法: 中心化后求协方差矩阵 (肯定是方阵), 对协方差矩阵求特征值和特征向量, 特征

值最大的几个特征向量组成的矩阵就是使得降维后保留信息最多的**线性映射**

2. 具体的选取步骤（线性代数逻辑）

假设你的高维数据是 m 维的，你想降到 k 维 ($k < m$)。PCA的选取分为以下严格的数学步骤：

第一步：中心化（去均值）

先把所有数据点平移，使整个数据集的中心（均值）位于原点。这一步是为了确保方差的计算不受位置影响。

第二步：计算协方差矩阵

构建一个 $m \times m$ 的协方差矩阵。这个矩阵记录了**每一对维度之间的相关性**。如果两个维度变化趋势一致，协方差为正；如果相反，协方差为负。

第三步：求解特征值与特征向量（最关键）

对协方差矩阵进行特征分解（Eigen-decomposition），求出它的特征值（Eigenvalues）和对应的特征向量（Eigenvectors）。

- **特征向量**：代表了一个**方向**（即候选的映射轴）。
- **特征值**：代表数据投影到该特征向量方向上的**方差大小**。

第四步：排序与选取（降维）

将特征值按**从大到小**排序。

- 最大的特征值对应的特征向量，就是**第一主成分（PC1）**——数据散得最开的方向。
- 第二大的特征值对应的特征向量，就是**第二主成分（PC2）**——并且它必须与PC1正交（垂直），保证信息不重复。
- 以此类推，你只需要挑出**前 k 个**最大特征值对应的特征向量，组成投影矩阵 W 。

最终映射公式：

$$\text{降维后的数据} = \text{原始数据} \times W$$

这就是将高维点投影到由这 k 个特征向量张成的低维子空间上。

概率论

概率密度函数及其性质

描述连续型随机变量出现在某个确定的取值点附近的可能性大小的一个函数

随机变量分布函数是概率密度函数的积分

性质：非负可积函数；负无穷到正无穷范围上积分为1

大数定律

伯努利大数定律：当重复独立试验次数 n 足够大时，事件A出现的频率将几乎接近于其发生的概率，即频率的稳定性。

切比雪夫大数定律：随着样本容量 n 的增加，样本平均数将接近于样本期望的平均数。

辛钦大数定律：当 n 越大时，前 n 个独立同分布变量的算数平均值越接近单个随机变量的数学期望。

什么是中心极限定理？

大量独立的随机变量之和近似服从正态分布。

棣莫弗-拉普拉斯中心极限定理： n 重伯努利（二项分布）在 n 趋于极限时服从正态分布

列维-林德伯格中心极限定理：大量独立同分布的随机变量之和时正态变量

概率论与数理统计的联系

概率论是已知数据的分布计算事件概率；数理统计是从样本或事件的发生推断总体的分布

概率论是数理统计的理论基础

协方差矩阵是什么

协方差矩阵是用来描述**多维数据里,每一对维度之间如何一起变化**的矩阵。

d 维向量 $x = (x^{(1)}, \dots, x^{(d)})$, 每个元素代表一个随机变量, 想知道每一对维度 $x^{(p)}, x^{(q)}$ 之间的协方差, 把所有 $d \times d$ 种组合都算出来, 排成一个矩阵:

$$C_{pq} = \text{Cov}(x^{(p)}, x^{(q)}) = \frac{1}{n-1} \sum_{i=1}^n (x_i^{(p)} - \bar{x}^{(p)})(x_i^{(q)} - \bar{x}^{(q)})$$

这就是协方差矩阵 C 的第 (p, q) 个元素。写成矩阵形式(数据已中心化, 即 X 每列均值为0):

(注意因为这里使用样本观测值去估计, 所以分母是 $n-1$ 而不是 n , 协方差理论上应该是 n 为分母)

$$C = \frac{1}{n-1} X^T X \in \mathbb{R}^{d \times d}$$

- **对角线元素** C_{pp} : 就是第 p 维自己的方差, 衡量这一维度本身有多分散。
- **非对角线元素** $C_{pq} (p \neq q)$: 第 p 维和第 q 维的协方差, 衡量这两个维度是否存在线性相关的联动。
- C 是**对称矩阵** ($C_{pq} = C_{qp}$), 且是**半正定**的(前面聊过的性质, 因为对任意 $w, w^T C w$ 就是投影方差, 天然 ≥ 0)。

跟 PCA 的联系

协方差矩阵里如果非对角元素很大, 说明维度之间高度相关、有冗余信息——比如两个特征几乎线性相关, 那这两维其实只携带了大约一维的信息量。PCA 做的事情, 本质上就是找一组新坐标轴(特征向量), 让新坐标系下协方差矩阵变成对角矩阵——也就是**去掉维度之间的相关性**, 新坐标轴之间协方差为0, 只剩对角线上的方差(即特征值), 这样每个主成分就携带了独立的、不重叠的信息量。

为什么概率分布函数是右连续的?

因为概率分布函数中是 $F(X \leq x)$, 这个小于等于决定了右连续的性质, 测度论中这个形式天然具有右连续的性质, 如果分布函数出现了跳跃(如离散的概率), 那么这个间距会出现在左极限和 $F(x_0)$ 处

(测度论中的**上方连续性**)

如果是左连续(即定义 $F(x) = P(X < x)$), 那么在**离散点**上就会出现“质量丢失”的问题。

MME（矩估计）和MLE（最大似然估计）

矩估计和MLE在估计正态分布的期望和方差的时候算式结果是一样的
但是在其他分布上并不一定一样（如平均分布等预测结果就不一样）

区间估计

随机过程

1. 什么是随机过程？（核心定义）

随机过程 是一族定义在同一个概率空间上的随机变量，它们由参数 t 索引，通常 t 表示时间。

$$\{X(t), t \in T\}$$

- 当 t 固定时， $X(t)$ 是一个**随机变量**。
- 当随机试验的结果（样本点 ω ）固定时， $X(t, \omega)$ 是时间 t 的一个**确定性函数**，称为**样本轨道或实现**（sample path）。

2. 随机过程的分类（两大维度）

分类维度	类型	说明
状态空间	离散状态	取值是离散的（如排队人数、掷骰子次数）
	连续状态	取值是连续的（如温度、电压）
时间参数	离散时间	$T = \{0, 1, 2, \dots\}$ （如时间序列）
	连续时间	$T = [0, \infty)$ （如布朗运动）

最常见的一种离散时间、离散状态的随机过程就是**马尔可夫链**。

平稳随机过程

过程的统计规律不随时间平移而改变。

严平稳随机过程：

任意时间点的随机变量构成的联合分布函数不随时间的平移而发生改变；过程的**任意有限维分布**在时间平移下保持不变。

宽平稳随机过程：

一阶矩（均值）不随时间变化而变化；自相关函数只与时间差值有关系；二阶矩存在，即方差有限。

严平稳不一定是宽平稳（因为二阶矩可能不存在）（存在二阶矩的严平稳过程必为宽平稳过程），宽平稳也不一定是严平稳（因为高阶分布可能随时间变化）。但正态过程中，宽平稳等价于严平稳。

ps:严平稳过程并不要求过程中的各个随机变量相互独立，严平稳关心的是“依赖模式是否随时

间改变”，而不是“是否存在依赖”。只要依赖模式不随时间漂移，无论依赖多强，都可以是严平稳的。

通过**维纳-辛钦公式**，宽平稳过程的自相关函数与功率谱密度之间存在傅里叶变换关系

各态历经性

对于平稳随机过程，我们通常想估计它的**统计平均**（如均值 $E[X(t)]$ ）和**自相关函数**。但我们只有一条样本轨道（一次试验的记录），怎么办？

- **集合平均**（Ensemble Average）：对同一时刻的所有可能结果取平均（需要无数次重复试验）。
- **时间平均**（Time Average）：对一条足够长的样本轨道，在时间轴上取平均。
若时间平均能代替集合平均，则称该过程关于均值具有**各态历经性**

一般而言只有独立同分布的白噪声充分地具备各态历经性

其他的随机过程

过程类型	核心特征	典型例子
马尔可夫过程	给定现在，将来与过去独立（无后效性）	排队系统、语言模型
高斯过程	任意有限维分布都是正态分布	机器学习中的高斯过程回归
泊松过程	计数过程，增量独立且服从泊松分布	电话呼叫次数、网页访问量
维纳过程（布朗运动）	连续时间、连续状态，增量独立正态	物理扩散、金融布朗运动模型

白噪声

白噪声最重要的特征在于其自相关函数除了在0处不为0，其他点处处为0；其功率谱密度是一个常数，表明其各频段的功率均匀分布。

自相关函数为0意味着没有线性关系，不代表独立

白噪声并不一定是严平稳随机过程，如果各个时间点之间仅仅是“不相关”的关系，那它一般只满足宽平稳随机过程，不保证高阶的相关结构。但如果是时间点之间相互独立，则满足严平稳随机过程

自相关函数、自协相关函数

自相关函数 (Autocorrelation Function) 和 **自协方差函数 (Autocovariance Function)** 是两个高度相关但不同的概念，区别在于**是否中心化 (是否减去均值)**。

函数名称	公式 (一般情况)	公式 (宽平稳过程)
自协方差函数	$C(t_1, t_2) = E[(X(t_1) - \mu(t_1))(X(t_2) - \mu(t_2))]$	$C(\tau) = E[(X(t) - \mu)(X(t + \tau) - \mu)]$
自相关函数	$R(t_1, t_2) = E[X(t_1)X(t_2)]$	$R(\tau) = E[X(t)X(t + \tau)]$

两者的关系：

$$C(t_1, t_2) = R(t_1, t_2) - \mu(t_1)\mu(t_2)$$

- 如果过程的均值为 0 (零均值过程)，那么自协方差 = 自相关 (因为减去的项为 0)。
- 如果均值不为 0，两者就差一个常数乘积项。

在工程和信号处理中，如果均值已知且不为 0，人们习惯用**自协方差**来分析波动部分；如果研究信号的总能量 (包括直流分量)，则用**自相关**。

自相关函数、互相关函数

对于两个随机过程 $X(t)$ 和 $Y(t)$ ，互相关函数定义为 $R_{XY}(\tau) = E[X(t)Y(t + \tau)]$

你可以直接和自相关对比： $R_X(\tau) = E[X(t)X(t + \tau)]$

互相关一个特别重要的用途就是：估计两个信号之间的时间延迟

[cs 保研经验贴 | 数学试题 · 自动化所特供版 - MoonOut - 博客园](#)